

# TAREA COMPLEMENTARIA

## Aprendizaje Supervisado

Ingeniería de Software · 7mo Semestre

### Contexto del problema

Eres analista de datos en una empresa de recursos humanos. Tu jefe necesita un sistema que prediga si un empleado renunciará en los próximos 6 meses, basándose en características

recopiladas durante su permanencia en la empresa. No existe un dataset listo: debes construirlo tú, entrenarlo y demostrar que tu modelo tiene valor predictivo real.

## 1. Creación del Dataset

Debes construir un dataset original de mínimo 300 registros simulando una empresa real. El dataset debe ser coherente y verosímil — no valores aleatorios sin sentido.

### Variables obligatorias (features)

- edad: número entero entre 22 y 60
- años\_en\_empresa: entre 0 y 20, coherente con la edad
- salario\_mensual: en dólares, coherente con el puesto
- horas\_extra\_semana: entre 0 y 20
- satisfaccion\_laboral: escala 1-5 (1=muy insatisfecho, 5=muy satisfecho)
- num\_proyectos\_año: entre 1 y 10
- distancia\_casa\_trabajo\_km: entre 1 y 80
- ultima\_evaluacion\_desempeño: score entre 0.0 y 1.0
- capacitaciones\_recibidas: entre 0 y 5 por año
- tiene\_ascenso\_ultimos\_2\_años: 0 o 1

### Variable objetivo

- renuncia: 1 = renunció en los próximos 6 meses, 0 = se quedó

### Regla de coherencia — OBLIGATORIA

El dataset NO puede ser aleatorio puro. Debes programar lógica de generación que refleje relaciones reales: por ejemplo, satisfaccion\_laboral baja + horas\_extra altas debe aumentar la probabilidad de renuncia. Documenta en el informe qué reglas usaste. Un dataset sin lógica interna tendrá penalización en la nota.

## 2. Análisis Exploratorio (EDA)

---

1. Calcula y muestra estadísticas descriptivas completas del dataset (media, std, min, max, percentiles).
2. Genera un heatmap de correlación entre todas las variables numéricas. Identifica las 3 correlaciones más fuertes con la variable objetivo.
3. Grafica la distribución de la variable renuncia. ¿Está balanceado el dataset? Si no, documenta qué harás al respecto.
4. Genera boxplots de salario\_mensual y satisfaccion\_laboral separados por la variable renuncia. ¿Qué patrones observas?

## 3. Modelado — Mínimo 3 algoritmos

---

Debes implementar y comparar los siguientes tres algoritmos de clasificación supervisada:

- Regresión Logística — modelo base de referencia
- Random Forest — modelo de ensamble
- Gradient Boosting (XGBoost o sklearn) — modelo avanzado

**Para cada modelo debes:**

5. Dividir el dataset: 80% entrenamiento, 20% prueba. Usar random\_state=42.
6. Estandarizar features numéricas con StandardScaler (ajustar SOLO sobre train).
7. Entrenar el modelo y predecir sobre el conjunto de prueba.
8. Calcular: Accuracy, Precisión, Recall, F1-Score y AUC-ROC.
9. Graficar la curva ROC de los 3 modelos en una sola figura para comparar.
10. Graficar la matriz de confusión de cada modelo.
11. Para Random Forest y Gradient Boosting: graficar feature importance.

## 4. Optimización con Cross-Validation

---

12. Aplicar k-fold cross-validation (k=5) al mejor modelo. Reportar la media y desviación estándar del F1-Score.
13. Aplicar GridSearchCV o RandomizedSearchCV para optimizar al menos 3 hiperparámetros del mejor modelo. Documentar qué parámetros probaste y cuál fue el mejor conjunto.
14. Comparar el modelo base vs el modelo optimizado con una tabla de métricas.

## 5. Preguntas Técnicas

---

Estas preguntas deben responderse en el informe PDF Y explicarse verbalmente en el video mostrando el gráfico o código correspondiente.

### Preguntas para el Informe (respuesta escrita)

15. ¿Por qué estandarizas las features antes de entrenar Regresión Logística pero no es estrictamente necesario para Random Forest? Explica el fundamento matemático.
1. Tu dataset tiene una distribución de clases  $X\%$  /  $Y\%$ . ¿Esto afecta las métricas? ¿Por qué el Accuracy puede ser engañoso en este caso y qué métrica es más confiable?
2. Explica con tus propias palabras qué significa un AUC-ROC de 0.85 para tu modelo. ¿Qué implica para el negocio de RRHH?
3. Mirando el feature importance de tu Random Forest, ¿cuál variable resultó más importante para predecir la renuncia? ¿Coincide con lo que esperabas al diseñar el dataset? ¿Por qué sí o no?
4. ¿Cuál es la diferencia entre Precisión y Recall? En el contexto de predecir renunciaciones, ¿cuál de las dos priorizarías y por qué? (considera el costo de cada tipo de error).
5. Después de aplicar GridSearchCV, ¿mejoraron significativamente las métricas? ¿Qué hiperparámetro tuvo mayor impacto y por qué crees que fue ese?

### Preguntas para el Video (responder en vivo mostrando el código/gráfico)

6. Abre el notebook, ejecuta la celda de la curva ROC y explica en vivo por qué un modelo está por encima del otro.
7. Señala en tu código exactamente dónde aplicas StandardScaler y explica por qué lo ajustas solo con datos de entrenamiento.
8. Muestra la matriz de confusión de tu mejor modelo y explica qué significa cada cuadrante en términos del problema de negocio.
9. ¿Qué pasaría si alguien te dice que tu modelo tiene 95% de accuracy — sería eso suficiente para confiar en él? Responde mirando tus propios resultados.

## 6. Entregables

### Entregables obligatorios — los tres deben estar presentes

- ① CÓDIGO: Link a repositorio GitHub o Google Colab. Debe ejecutarse de inicio a fin sin errores. Incluir comentarios que expliquen cada sección.
- ② INFORME PDF: Máximo 6 páginas. Estructura:
  - Descripción del dataset creado y reglas de coherencia usadas
  - Análisis exploratorio con gráficos y hallazgos
  - Tabla comparativa de métricas de los 3 modelos
  - Respuestas a las 6 preguntas técnicas escritas
  - Conclusiones: ¿cuál modelo recomendarías a la empresa y por qué?

**③ VIDEO (4-5 minutos): Rostro visible en todo momento.****Estructura del video:**

- 00:00-00:30 Presentación y descripción del dataset creado
- 00:30-02:00 Mostrar y explicar los gráficos más importantes
- 02:00-04:00 Responder las 4 preguntas técnicas del video en vivo
- 04:00-05:00 Conclusión: modelo elegido y justificación

## 7. Rúbrica de Evaluación

| Componente                 | Porcentaje | Criterios de evaluación                                                                                                                                                      |
|----------------------------|------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Código funcional           | 25%        | Corre sin errores · Lógica correcta · Bien estructurado y comentado · Usa el dataset propio · Incluye las visualizaciones requeridas                                         |
| Video con rostro (4-5 min) | 40%        | Rostro visible en todo momento · Responde correctamente las preguntas técnicas · Muestra y explica cada gráfico generado · Demuestra comprensión real del algoritmo          |
| Informe PDF                | 35%        | Documenta el proceso de creación del dataset · Responde las preguntas escritas con fundamento técnico · Incluye capturas de gráficos con análisis · Redacción propia y clara |
| TOTAL                      | 100%       | Nota sobre 10 puntos                                                                                                                                                         |

**Criterios de penalización**

- Dataset con valores aleatorios sin lógica coherente: -2 puntos
- Código que no corre o genera errores: 0% en ese componente
- Video sin rostro visible o grabado en pantalla sin cámara: 0% en video
- Respuestas copiadas literalmente de fuentes externas sin elaboración propia: -1 punto
- No incluir todos los gráficos requeridos: -0.5 por gráfico faltante